

Seção 1: Preparação de Dados

Importação e Limpeza de Dados:

```
In [1]: # Importando bibliotecas necessárias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from statsmodels.tsa.statespace.sarimax import SARIMAX
from pmdarima import auto_arima
from sklearn.metrics import mean_absolute_error, mean_squared_error
from scipy import stats
from statsmodels.tsa.arima.model import ARIMA
import plotly.express as px
import plotly.graph_objects as go
import statsmodels.api as sm

# Carregando o conjunto de dados financeiro
df = pd.read_csv('/Users/tsumano/Downloads/sistema de pedidos 05-09-2024.csv', encoding='latin1', sep=';')

# Visualizando as primeiras linhas do dataset
df.head()
```

Out[1]:

	Numero do pedido	Pedido SC	Agendamento	PDI	Cliente	Segmento	Data do recebimento	Data de finalização (desejada)	Produto (nu cat)	Quantidade no pedido	...	Custo de deslocamento	IPI	Prazo de pagamento	CNPJ faturamento	para	Local de entrega	Nome	C
0	16605	MANUTENÇÃO		NaN	NaN	Experience Locadora	Locadoras	05/09/2024	12/09/2024	SUNTECH	1	...	NaN	30 DIAS	NaN	009.206.045- 52	mesmo do cliente	Adson Souza da Silva	009.206.0
1	16604	REMOÇÃO		NaN	NaN	Localiza	Locadoras	05/09/2024	09/09/2024	SHE1F49	1	...	NaN	30 DIAS	NaN	NaN	mesmo do cliente	NaN	
2	16603	REMOÇÃO		NaN	NaN	Localiza	Locadoras	05/09/2024	09/09/2024	RMK4I90	1	...	NaN	30 DIAS	NaN	NaN	mesmo do cliente	NaN	
3	16602	REMOÇÃO		NaN	NaN	Localiza	Locadoras	05/09/2024	09/09/2024	RVI0F57	1	...	NaN	30 DIAS	NaN	NaN	mesmo do cliente	NaN	
4	16601	REMOÇÃO		NaN	NaN	Localiza	Locadoras	05/09/2024	09/09/2024	RVA2D50	1	...	NaN	30 DIAS	NaN	NaN	mesmo do cliente	NaN	

5 rows × 29 columns

Valores Ausentes

```
In [2]: # Verificando informações gerais do dataset, como tipos de dados e valores ausentes
df.info()

# Identificando valores ausentes
df.isnull().sum()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 27404 entries, 0 to 27403
Data columns (total 29 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Numero do pedido                         27404 non-null  int64
1   Pedido SC                               13689 non-null  object
2   Agendamento                             546 non-null    object
3   PDI                                      1098 non-null   object
4   Cliente                                27404 non-null  object
5   Segmento                               24933 non-null  object
6   Data do recebimento                     27404 non-null  object
7   Data de finalização (desejada)          27399 non-null  object
8   Produto (nu cat)                        27404 non-null  object
9   Quantidade no pedido                    27404 non-null  int64
10  Separados                              27404 non-null  object
11  Entrega                                27404 non-null  object
12  Previsão De Instalação                   19925 non-null  object
13  Instalados                             27404 non-null  object
14  Local de instalações                     27266 non-null  object
15  Status                                  27404 non-null  object
16  Frete                                   22049 non-null  object
17  Custo de cofre                           15419 non-null  object
18  Custo de instalação                      17149 non-null  object
19  Custo de deslocamento                   1495 non-null   object
20  IPI                                      17240 non-null  object
21  Prazo de pagamento                      0 non-null      float64
22  CNPJ para faturamento                   10986 non-null  object
23  Local de entrega                         17107 non-null  object
24  Nome                                    7670 non-null   object
25  CNPJ                                    6622 non-null   object
26  Endereço                               7677 non-null   object
27  Tel                                     1912 non-null   object
28  Observações                             13984 non-null  object
dtypes: float64(1), int64(2), object(26)
memory usage: 6.1+ MB
```

```
Out[2]: Numero do pedido          0
        Pedido SC                 13715
        Agendamento              26858
        PDI                      26306
        Cliente                   0
        Segmento                 2471
        Data do recebimento       0
        Data de finalização (desejada) 5
        Produto (nu cat)         0
        Quantidade no pedido      0
        Separados                 0
        Entrega                   0
        Previsão De Instalação    7479
        Instalados                0
        Local de instalações      138
        Status                    0
        Frete                     5355
        Custo de cofre            11985
        Custo de instalação       10255
        Custo de deslocamento    25909
        IPI                      10164
        Prazo de pagamento       27404
        CNPJ para faturamento    16418
        Local de entrega         10297
        Nome                      19734
        CNPJ                     20782
        Endereço                 19727
        Tel                      25492
        Observações              13420
        dtype: int64
```

```
In [3]: # Removendo colunas irrelevantes com muitos valores ausentes
columns_to_remove = [
    'Pedido SC', 'Agendamento', 'PDI', 'Custo de deslocamento', 'Prazo de pagamento',
    'Nome', 'CNPJ', 'Endereço', 'Tel', 'Observações'
]
df = df.drop(columns=columns_to_remove)
```

```
In [4]: # Removendo caracteres não numéricos e convertendo para tipo numérico
df['Custo de cofre'] = df['Custo de cofre'].replace('[\D]', '', regex=True) # Removendo caracteres não numéricos
df['Custo de cofre'] = pd.to_numeric(df['Custo de cofre'], errors='coerce') # Convertendo para tipo numérico
# Preenchendo valores ausentes com a mediana
df['Custo de cofre'] = df['Custo de cofre'].fillna(df['Custo de cofre'].median())
```

```
In [5]: print(df['Custo de instalação'].unique())
```

'30' '150' '50' nan '0' '40' '20' '120' '70' '75' '350' '100' '180' '29'
'60' '85' '19,54' '90' '170' '250' '25' '280' '200,4' '80' '300' '190'
'SANGUESSUGA 178,' '150.00' 'KIT R r\$39,00' '0.00' '450' '300.00' '200'
'145' '380' '480' '30 DIAS' '295,6' '35' '230' '140' '220' '19,65'
'KIT R R\$39,00' '540' '550' '17' '43,4' '570' '350,00' '580' '490'
'250,00 DIARIA' '260' '317,70 +ST - BR2' '43.40' '43' '150,00 + 50,00 -'
'320' '150,00 + 50,00' '50,00 SS' '150,00+ 50,00 SS' '150,00 + 50,00 S'
'335,64' '43.,40' '240' '92,4' '17.00' '160' '66' '92' '91' '77,5'
'92.40' '315,2' '87.50' '87,5' '37,5' '110' '55' '130' '92,40 + 09,90 SA'
'84,6' '-' '290' '20 ,00' 'R\$ 30.00' 'R\$ 1.30 DE DESCO' '49,2' '144' '77'
'175' '610' '311' '84' '225' '66.00' '340' '72,5' 'R\$ 70,00' 'R\$ 77,50'
'58,22' '36' '209' '80,00 CADA' '40,00+ 260,00 DE' '1.00'
'40,00 + 200,00 d' '380,00 APROVADO' 'R\$ 30,00' '70,00+ DES 188,' '330'
'400' '250,00 aprovado' '250,00APROVADO' '450,00 aprovado'
'50 DESLOCAMENTO' '350,00aprovado' '310' '350,00 aprovado'
'92,40 + 29,90 ub' '400,00 aprovado' '400,00APROVADA' '500,00+ 56,40'
'310,00 APROVADO' '150,00+70,00' '92,40 + 220,00' '400 APROVADO'
'550,00 aguardand' '92,40 + 250,00 D' '500' '350,00 APROVADO'
'400 aprovado' '-350 APROVADO' '800,00 TOTAL' '-150' '500 APROVADA'
'-300' '-300 APROVADA' '-450' '150,00 PAGO' '647,00 aguardand'
'-450 APROVADO' '700,00 AGUARDAND' '92,40 +200' '300,00aprovada'
'350 APROVADA' '84.60' '350 aprovado' '105' '350,00 aprovada'
'450,00 APROVADA' '150 dias' '300,00 aprovada' '77,55' '300,00 aprovado'
'42,5' '280,00 DESLOCAME' '350,00 remoção' '400 remoção = de'
'400,00 remoção +' '77,50 + 274,40 D' '50,00+170,00 DES'
'250,00 DESLOCAME' '200 DESLOCAMENTO' '72' '150 deslocamento'
'77,50 + 126,84' '250 DESLOCAMENTO' '150 DESLOCAMENTO' '211,96 + 77,50 d'
'173' '50,00 + 250,00 D' '100,00 desloca' '200 deslocamento'
'230,00 desloca' '285' '150,00 desloca' '100 deslocamento' '125'
'125 DESLOCAMENTO' '450 deslocamento' '210' '250,00 desloca'
'77,50+ 487,20 DE' '100,00 DESLOCAME' '87,50.' '147,1' '500 deslocamento'
'50,00 desloca' '40,00+ 250 deslo' '40,00+ 140,00 de'
'40,00+ 280,00 DE' '40,00 + 665,60 d' '250 deslocamento'
'100 DESLOCAMENTO' '4.600' '300 DESLOCAMENTO' '600,00 remoção'
'125,00 DESLOCAME' '50,00 DESLOCAMEN' '1.000,00' '80,00 + 431,20'
'350 deslocamento' '134' 'DESLOCAMENTO\$450' '123,2' '460,32 NOW SHOW'
'431,20 DESLOCAME' '850,00 REMOÇÃO' '300,00 desloca' '150,00+ 250,00 d'
'750 de desloca' '220 deslocamento' '92,5' '92,50 desloca'
'78,40 DEVOLUÇÃO' '92,7' '37' '87']

```
In [6]: # Limpando a coluna 'Custo de instalação'

# Função para limpar e converter valores
def limpar_custo(valor):
    if pd.isna(valor):
        return np.nan
    valor = str(valor).replace(',', '.').replace('R$', '').replace(' ', '').replace('+', '').replace('APROVADO', '').replace('DESLOCAMENTO', '').replace('DESLOCAME', '').replace('R$', '')
    try:
        return float(valor)
    except ValueError:
        return np.nan

# Aplicando a função de limpeza
df['Custo de instalação'] = df['Custo de instalação'].apply(limpar_custo)

# Preenchendo valores ausentes com a mediana
df['Custo de instalação'] = df['Custo de instalação'].fillna(df['Custo de instalação'].median())

# Verificando a limpeza e conversão
print("Amostra dos dados da coluna 'Custo de instalação':")
```

```
print(df['Custo de instalação'].head(10))

# Obtendo estatísticas descritivas da coluna 'Custo de instalação'
print("\nEstatísticas descritivas da coluna 'Custo de instalação':")
print(df['Custo de instalação'].describe())

# Verificando valores ausentes na coluna 'Custo de instalação'
print("\nNúmero de valores ausentes na coluna 'Custo de instalação':")
print(df['Custo de instalação'].isnull().sum())
```

Amostra dos dados da coluna 'Custo de instalação':

```
0    30.0
1   150.0
2   150.0
3   150.0
4   150.0
5   150.0
6   150.0
7   150.0
8    50.0
9    66.0
```

Name: Custo de instalação, dtype: float64

Estatísticas descritivas da coluna 'Custo de instalação':

```
count    27404.000000
mean       69.527526
std       56.316986
min      -450.000000
25%       40.000000
50%       66.000000
75%       87.500000
max       800.000000
```

Name: Custo de instalação, dtype: float64

Número de valores ausentes na coluna 'Custo de instalação':

```
0
```

```
In [7]: # 1. Removendo prefixos e valores inválidos
df['Frete'] = df['Frete'].replace({'Nao': np.nan, 'A ver': np.nan}, regex=True) # Remove valores inválidos
df['Frete'] = df['Frete'].replace(r'^R\$ ', '', regex=True) # Remove prefixos como 'R$ '
df['Frete'] = df['Frete'].replace(r'^\d,', '', regex=True) # Remove caracteres não numéricos, exceto vírgulas

# 2. Substituindo vírgulas por pontos e convertendo para float
df['Frete'] = df['Frete'].str.replace(',', '.', regex=False) # Substitui vírgulas por pontos
df['Frete'] = pd.to_numeric(df['Frete'], errors='coerce') # Converte para float, forçando erros a NaN

# 3. Preenchendo valores ausentes com a mediana
df['Frete'] = df['Frete'].fillna(df['Frete'].median())
```

```
In [8]: # Substituindo texto e caracteres não numéricos por NaN
df['IPI'] = df['IPI'].replace({
    r'^\d,': np.nan, # Substitui caracteres não numéricos por NaN
    'nan': np.nan,   # Substitui valores 'nan' como string por NaN
    '-': np.nan      # Substitui '-' por NaN
}, regex=True)

# 2. Substituindo vírgulas por pontos e convertendo para float
df['IPI'] = df['IPI'].str.replace(',', '.', regex=False) # Substitui vírgulas por pontos
df['IPI'] = pd.to_numeric(df['IPI'], errors='coerce')     # Converte para float, forçando erros a NaN
```

```
# 3. Preenchendo valores ausentes com a mediana
df['IPI'] = df['IPI'].fillna(df['IPI'].median())
```

```
In [9]: # Preenchendo valores ausentes na coluna 'Segmento' com a moda
moda_segmento = df['Segmento'].mode()[0]
df['Segmento'] = df['Segmento'].fillna(moda_segmento)

# Removendo linhas com valores ausentes na coluna 'Data de finalização (desejada)'
df = df.dropna(subset=['Data de finalização (desejada)'])

# Preenchendo valores ausentes na coluna 'Previsão De Instalação' com 'Desconhecido'
df['Previsão De Instalação'] = df['Previsão De Instalação'].fillna('Desconhecido')

# Preenchendo valores ausentes na coluna 'Local de instalações' com 'Desconhecido'
df['Local de instalações'] = df['Local de instalações'].fillna('Desconhecido')

# Preenchendo valores ausentes na coluna 'Custo de cofre' com a mediana
df['Custo de cofre'] = df['Custo de cofre'].fillna(df['Custo de cofre'].median())

# Preenchendo valores ausentes na coluna 'CNPJ para faturamento' com 'Desconhecido'
df['CNPJ para faturamento'] = df['CNPJ para faturamento'].fillna('Desconhecido')

# Preenchendo valores ausentes na coluna 'Local de entrega' com 'Desconhecido'
df['Local de entrega'] = df['Local de entrega'].fillna('Desconhecido')
```

```
In [10]: # Verificando se as colunas possuem multi-índice
if isinstance(df.columns, pd.MultiIndex):
    # Flattening multi-index columns
    df.columns = [' '.join(col).strip() for col in df.columns]

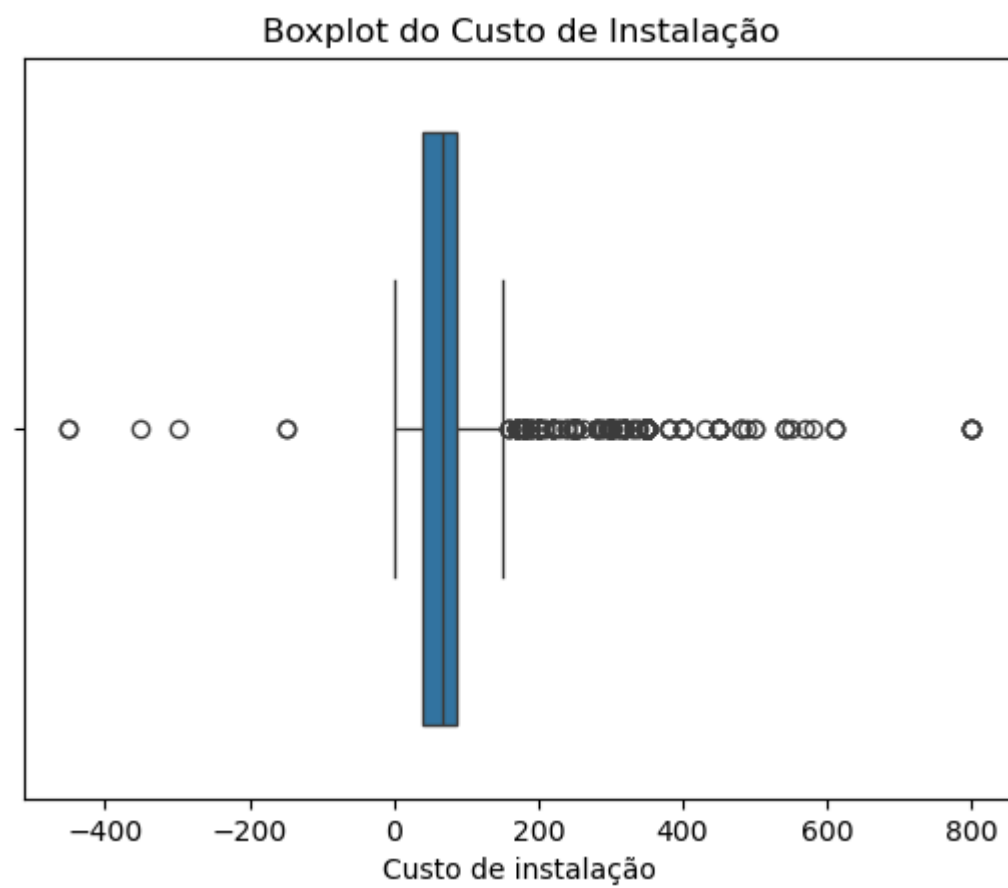
# Calculando a média e o desvio padrão do 'Custo de instalação'
mean = df['Custo de instalação'].mean()
std_dev = df['Custo de instalação'].std()

# Identificando os outliers
outliers = (df['Custo de instalação'] > mean + 3 * std_dev) | (df['Custo de instalação'] < mean - 3 * std_dev)

# Calculando a mediana do 'Custo de instalação'
mediana = df['Custo de instalação'].median()
```


Outliers

```
In [11]: # Criando um boxplot para visualizar os outliers
sns.boxplot(x=df['Custo de instalação'])
plt.title('Boxplot do Custo de Instalação')
plt.show()
```



```
In [12]: # Substituindo os outliers pela mediana
df.loc[outliers, 'Custo de instalação'] = mediana

# Criando um boxplot para visualizar se outliers foram corretamente tratados
sns.boxplot(x=df['Custo de instalação'])
plt.title('Boxplot do Custo de Instalação')
plt.show()
```



```
In [13]: # Listando todas as colunas numéricas
numeric_columns = df.select_dtypes(include=['float64', 'int64']).columns
print(numeric_columns)
```

```
Index(['Numero do pedido', 'Quantidade no pedido', 'Frete', 'Custo de cofre',
      'Custo de instalação', 'IPI'],
      dtype='object')
```

```
In [14]: # Identificando outliers com base no IQR para cada coluna numérica
outliers_dict = {}

for col in numeric_columns:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1
    lower_bound = Q1 - 1.5 * IQR
    upper_bound = Q3 + 1.5 * IQR

    # Encontrando os outliers
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
    outliers_dict[col] = outliers

# Verificando as colunas que possuem outliers
for col, outliers in outliers_dict.items():
    if not outliers.empty:
        print(f"Outliers encontrados na coluna: {col}, Número de outliers: {len(outliers)}")
```

```
Outliers encontrados na coluna: Quantidade no pedido, Número de outliers: 3884
Outliers encontrados na coluna: Frete, Número de outliers: 1230
Outliers encontrados na coluna: Custo de cofre, Número de outliers: 9790
Outliers encontrados na coluna: Custo de instalação, Número de outliers: 2465
Outliers encontrados na coluna: IPI, Número de outliers: 152
```


Duplicadas

```
In [15]: # Verificando duplicadas no DataFrame inteiro
duplicatas = df[df.duplicated()]

# Exibindo o número de duplicadas encontradas
print(f"Número de observações duplicadas: {len(duplicatas)}")

# Exibindo as duplicadas, caso existam
if not duplicatas.empty:
    print(duplicatas)
else:
    print("Nenhuma observação duplicada encontrada.")
```

Número de observações duplicadas: 20

	Numero do pedido	Cliente	Segmento	\
4228	13361	Yalla Transportes e Serviços	Locadoras	
17204	3993	Localiza	Locadoras	
23366	1600	Localiza	Locadoras	
24835	1080	Localiza	Locadoras	
24836	1080	Localiza	Locadoras	
24840	1079	Localiza	Locadoras	
24842	1078	Localiza	Locadoras	
24935	1067	Localiza	Locadoras	
24936	1067	Localiza	Locadoras	
25199	937	Localiza	Locadoras	
25342	882	Localiza	Locadoras	
26137	565	Localiza	Locadoras	
26191	550	Localiza	Locadoras	
26224	529	Localiza	Locadoras	
26480	432	Localiza	Locadoras	
26620	357	Unidas	Locadoras	
27072	144	Localiza	Locadoras	
27074	144	Localiza	Locadoras	
27227	96	Localiza	Locadoras	
27231	96	Localiza	Locadoras	

	Data do recebimento	Data de finalização (desejada)	Produto (nu cat)	\
4228	27/03/2024	01/04/2024	SUNTECH+BL0Q	
17204	03/10/2022	05/10/2022	BR172	
23366	16/05/2022	17/05/2022	BR214	
24835	01/04/2022	01/04/2022	BR221	
24836	01/04/2022	01/04/2022	BR221	
24840	01/04/2022	01/04/2022	BR222	
24842	01/04/2022	01/04/2022	BR152	
24935	31/03/2022	04/04/2022	BR218	
24936	31/03/2022	04/04/2022	BR218	
25199	23/03/2022	23/03/2022	BR153	
25342	17/03/2022	22/03/2022	BR177	
26137	17/02/2022	17/02/2022	BR153	
26191	17/02/2022	17/02/2022	BR156	
26224	16/02/2022	16/02/2022	BR167	
26480	08/02/2022	11/02/2022	BR202	
26620	03/02/2022	07/02/2022	BR158	
27072	07/01/2022	13/01/2022	BR172	
27074	07/01/2022	13/01/2022	BR171	
27227	05/01/2022	07/01/2022	BR174	
27231	05/01/2022	07/01/2022	BR161	

	Quantidade no pedido	Separados	Entrega	Previsão De Instalação	\
4228	1	28/03/2024	28/03/2024	Desconhecido	
17204	2	04/10/2022	04/10/2022	-	
23366	1	17/05/2022	17/05/2022	-	
24835	1	01/04/2022	01/04/2022	-	
24836	1	01/04/2022	01/04/2022	-	
24840	1	01/04/2022	01/04/2022	-	
24842	1	01/04/2022	01/04/2022	-	
24935	2	04/04/2022	05/04/2022	-	
24936	2	04/04/2022	05/04/2022	-	
25199	1	23/03/2022	23/03/2022	-	
25342	2	18/03/2022	22/03/2022	-	
26137	3	18/02/2022	18/02/2022	-	
26191	1	17/02/2022	17/02/2022	-	
26224	1	16/02/2022	16/02/2022	-	

26480	3	10/02/2022	10/02/2022	-
26620	1	04/02/2022	04/02/2022	-
27072	2	13/01/2022	13/01/2022	-
27074	10	13/01/2022	13/01/2022	-
27227	4	11/01/2022	11/01/2022	-
27231	4	11/01/2022	11/01/2022	-

	Instalados	Local de instalações	Status	\
4228	02/04/2024	R. Lourenço Castanho, 193 – Vila Nova Conceiçã...	Done	
17204	-	KIP SOUND	Done	
23366	-	Endereço: Av. João Firmino, 165 – Assunção, Sã...	Done	
24835	-	LOCALIZA – PÁTIO CONSOLAÇÃO – LENILSON	Done	
24836	-	LOCALIZA – PÁTIO CONSOLAÇÃO – LENILSON	Done	
24840	-	LOCALIZA – ALPHAVILLE – KAIQUE	Done	
24842	-	LOCALIZA – SHOPPING SANTA CRUZ – EWERTON	Done	
24935	-	LOCALIZA – CPQ	Done	
24936	-	LOCALIZA – CPQ	Done	
25199	-	LOCALIZA – LAPA – LUIZ	Done	
25342	-	LOCALIZA – CONFINS	Done	
26137	-	LOCALIZA – VILA ANDRADE	Done	
26191	-	ZARP OSASCO	Done	
26224	-	LOCALIZA – SHOPPING D&D	Done	
26480	-	LOCALIZA – Rua Primavera, 1047, Bairro Rio Bra...	Done	
26620	-	RUA DOMINGOS DE MORAIS, 2564	Done	
27072	-	ZARP PAMPULHA	Done	
27074	-	ZARP PAMPULHA	Done	
27227	-	AVENIDA ARUANA 641 – TAMBORÉ/ FORNECEDOR TORQU...	Done	
27231	-	AVENIDA ARUANA 641 – TAMBORÉ/ FORNECEDOR TORQU...	Done	

	Frete	Custo de cofre	Custo de instalação	IPI	\
4228	91.15	2299.0	90.0	0.0	
17204	91.15	121.0	92.4	0.0	
23366	91.15	121.0	66.0	0.0	
24835	91.15	121.0	66.0	0.0	
24836	91.15	121.0	66.0	0.0	
24840	91.15	121.0	66.0	0.0	
24842	91.15	121.0	66.0	0.0	
24935	91.15	121.0	66.0	0.0	
24936	91.15	121.0	66.0	0.0	
25199	91.15	121.0	66.0	0.0	
25342	91.15	121.0	66.0	0.0	
26137	91.15	121.0	66.0	0.0	
26191	91.15	121.0	66.0	0.0	
26224	91.15	121.0	66.0	0.0	
26480	91.15	121.0	66.0	0.0	
26620	91.15	121.0	66.0	0.0	
27072	91.15	121.0	66.0	0.0	
27074	91.15	121.0	66.0	0.0	
27227	91.15	121.0	66.0	0.0	
27231	91.15	121.0	66.0	0.0	

	CNPJ para faturamento	Local de entrega
4228	33.011.265/0001-44	mesmo do cliente
17204	Desconhecido	mesmo do cliente
23366	Desconhecido	Desconhecido
24835	Desconhecido	Desconhecido
24836	Desconhecido	Desconhecido
24840	Desconhecido	Desconhecido
24842	Desconhecido	Desconhecido
24935	Desconhecido	Desconhecido

24936	Desconhecido	Desconhecido
25199	Desconhecido	Desconhecido
25342	Desconhecido	Desconhecido
26137	Desconhecido	Desconhecido
26191	Desconhecido	Desconhecido
26224	Desconhecido	Desconhecido
26480	Desconhecido	Desconhecido
26620	Desconhecido	Desconhecido
27072	Desconhecido	Desconhecido
27074	Desconhecido	Desconhecido
27227	Desconhecido	Desconhecido
27231	Desconhecido	Desconhecido

```
In [16]: # Verificando o número de observações
print(f"Número de observações após remover duplicatas: {df.shape[0]}")
```

Número de observações após remover duplicatas: 27399

```
In [17]: # Removendo duplicatas e mantendo a primeira ocorrência
df = df.drop_duplicates()

# Verificando o número de observações após a remoção
print(f"Número de observações após remover duplicatas: {df.shape[0]}")
```

Número de observações após remover duplicatas: 27379

Seção 2: Análise de Dados

Principais Métricas Financeiras

```
In [18]: # Calculando a receita total
df['Receita'] = df['Quantidade no pedido'] * df['Custo de instalação']
receita_total = df['Receita'].sum()

# Identificando fatores importantes
fatores_importantes = {
    'Receita Média por Cliente': df.groupby('Cliente')['Receita'].mean().mean(),
    'Receita Média por Produto': df.groupby('Produto (nu cat)')['Receita'].mean().mean(),
    'Receita Média por Segmento': df.groupby('Segmento')['Receita'].mean().mean()
}

print(f"Receita Total: {receita_total}")
print(f"Fatores Importantes: {fatores_importantes}")
```

Receita Total: 32016270.446000002

Fatores Importantes: {'Receita Média por Cliente': 349.3897257885305, 'Receita Média por Produto': 181.9998452916312, 'Receita Média por Segmento': 555.3723616475808}

Visualização das Métricas ao Longo do Tempo

```
In [19]: # Convertendo a data para o formato datetime
df['Data de finalização (desejada)'] = pd.to_datetime(df['Data de finalização (desejada)'], format='%d/%m/%Y')

# Criando a coluna 'Mês' no formato de período
df['Mês'] = df['Data de finalização (desejada)'].dt.to_period('M').astype(str) # Convertendo para string

# Verificando o tipo de dado da coluna 'Mês'
print(df['Mês'].dtype)
print(df['Mês'].unique())
```

```

# Verificando o tipo de dado da coluna 'Receita'
print(df['Receita'].dtype)
print(df['Receita'].unique())

# Corrigindo a coluna 'Receita'
df['Receita'] = pd.to_numeric(df['Receita'], errors='coerce') # Convertendo para numérico
df = df.dropna(subset=['Receita']) # Removendo linhas onde 'Receita' é NaN

# Agrupando e calculando a receita mensal
receita_mensal = df.groupby('Mês')['Receita'].sum().reset_index()

# Calculando a receita acumulada
receita_mensal['Receita Acumulada'] = receita_mensal['Receita'].cumsum()

# Calculando a média móvel de 3 meses
receita_mensal['Média Móvel (3 meses)'] = receita_mensal['Receita'].rolling(window=3).mean()

# Preenchendo valores ausentes na coluna 'Média Móvel (3 meses)' com o valor anterior (método de interpolação)
receita_mensal['Média Móvel (3 meses)'] = receita_mensal['Média Móvel (3 meses)'].bfill()

# Verificando o DataFrame
print(receita_mensal.head())

# Plotando a receita mensal e a média móvel
plt.figure(figsize=(14, 7))
sns.lineplot(data=receita_mensal, x='Mês', y='Receita', label='Receita Mensal')
sns.lineplot(data=receita_mensal, x='Mês', y='Média Móvel (3 meses)', label='Média Móvel (3 meses)', color='orange')
plt.title('Receita Mensal e Média Móvel ao Longo do Tempo')
plt.xlabel('Mês')
plt.ylabel('Receita')
plt.xticks(rotation=45)
plt.legend()
plt.tight_layout()
plt.show()


```

```

object
['2024-09' '2024-08' '2024-07' '2024-06' '2024-05' '2024-04' '2024-03'
 '2024-02' '2024-01' '2023-12' '2023-11' '2023-10' '2023-09' '2023-08'
 '2023-07' '2023-06' '2023-05' '2023-04' '2023-03' '2023-02' '2023-01'
 '2022-12' '2022-11' '2022-10' '2022-09' '2022-08' '2022-07' '2022-06'
 '2022-05' '2022-04' '2022-03' '2022-02' '2022-01' '2021-12']
float64
[  30.  150.   50. ... 20130. 17490. 29172.]

```


	Mês	Receita	Receita Acumulada	Média Móvel (3 meses)
0	2021-12	143352.0	143352.0	453662.0
1	2022-01	651222.0	794574.0	453662.0
2	2022-02	566412.0	1360986.0	453662.0
3	2022-03	770220.0	2131206.0	662618.0
4	2022-04	751146.0	2882352.0	695926.0



Análise de Tendências

```
In [20]: # Agrupando e calculando a receita total por segmento e mês
receita_categoria = df.groupby(['Mês', 'Segmento'])['Receita'].sum().reset_index()


# Criando um gráfico de linhas para cada categoria
plt.figure(figsize=(14, 7))
sns.lineplot(data=receita_categoria, x='Mês', y='Receita', hue='Segmento')
plt.title('Receita Mensal por Categoria de Produto')
plt.xlabel('Mês')
plt.ylabel('Receita')
plt.xticks(rotation=45)
plt.legend(title='Segmento')
plt.tight_layout()
plt.show()
```



```
In [21]: # Agrupando e calculando a receita total por produto e mês
receita_produto = df.groupby(['Mês', 'Produto (nu cat)'])['Receita'].sum().reset_index()

# Selecionando os 10 produtos com maior receita total
top_produtos = receita_produto.groupby('Produto (nu cat)')['Receita'].sum().nlargest(10).index
receita_top_produto = receita_produto[receita_produto['Produto (nu cat)'].isin(top_produtos)]


# Criando um gráfico de linhas para os principais produtos
plt.figure(figsize=(14, 7))
sns.lineplot(data=receita_top_produto, x='Mês', y='Receita', hue='Produto (nu cat)')
plt.title('Receita Mensal dos Top 10 Produtos')
plt.xlabel('Mês')
plt.ylabel('Receita')
plt.xticks(rotation=45)
plt.legend(title='Produto', bbox_to_anchor=(1.05, 1), loc='upper left')
plt.tight_layout(pad=2.0)
plt.show()
```



```
In [22]: # Selecionando um produto específico para análise
produto_especifico = 'BR158'

# Filtrando dados para o produto específico
dados_produto = receita_produto[receita_produto['Produto (nu cat)'] == produto_especifico]

# Criando um gráfico de linha para o produto específico
plt.figure(figsize=(14, 7))
sns.lineplot(data=dados_produto, x='Mês', y='Receita', marker='o')
plt.title(f'Receita Mensal do Produto {produto_especifico}')
plt.xlabel('Mês')
plt.ylabel('Receita')
plt.xticks(rotation=45)
plt.grid(True)
plt.tight_layout(pad=2.0)
plt.show()
```


Análise Comparativa

```
In [23]: # Selecionando múltiplos produtos para comparação
produtos_selecionados = ['BR158', 'BR191'] # Exemplo de códigos de produtos

# Filtrando dados para os produtos selecionados
dados_comparacao = receita_produto[receita_produto['Produto (nu cat)'].isin(produtos_selecionados)]

# Criando um gráfico de linha para comparação
plt.figure(figsize=(14, 7))
sns.lineplot(data=dados_comparacao, x='Mês', y='Receita', hue='Produto (nu cat)', marker='o')
plt.title('Comparação de Receita Mensal Entre Produtos')
plt.xlabel('Mês')
plt.ylabel('Receita')
plt.xticks(rotation=45)
plt.grid(True)
plt.legend(title='Produto')
```

```
plt.tight_layout(pad=2.0)
plt.show()
```



```
In [24]: # Calculando estatísticas descritivas
estatisticas_produto = receita_produto.groupby('Produto (nu cat)')['Receita'].agg(['mean', 'median', 'std'])
print(estatisticas_produto)
```

	mean	median	std
Produto (nu cat)			
ABM6B41	66.0	66.0	NaN
BR152	70.0	70.0	NaN
BR158	55.0	55.0	21.213203
BR167	40.0	40.0	NaN
BR167R	66.0	66.0	NaN
...
teste 1	198.0	198.0	NaN
teste1	0.0	0.0	NaN
teste2	0.0	0.0	NaN
tttt	66.0	66.0	NaN
wqr3i97	66.0	66.0	NaN

[5543 rows x 3 columns]

```
In [25]: # Identificando outliers na receita
q1 = df['Receita'].quantile(0.25)
q3 = df['Receita'].quantile(0.75)
iqr = q3 - q1

outliers = df[(df['Receita'] < (q1 - 1.5 * iqr)) | (df['Receita'] > (q3 + 1.5 * iqr))]
print(outliers)
```

	Numero do pedido	Cliente	Segmento	Data do recebimento	\
47	16572	Localiza	Locadoras	05/09/2024	
48	16571	Movida	Locadoras	04/09/2024	
73	16560	Localiza	Locadoras	04/09/2024	
74	16560	Localiza	Locadoras	04/09/2024	
75	16560	Localiza	Locadoras	04/09/2024	
...	
27396	9	Localiza	Locadoras	24/12/2021	
27397	9	Localiza	Locadoras	24/12/2021	
27398	9	Localiza	Locadoras	24/12/2021	
27399	9	Localiza	Locadoras	24/12/2021	
27403	6	Movida	Locadoras	23/12/2021	

	Data de finalização (desejada)	Produto (nu cat)	Quantidade no pedido	\
47	2024-09-09	BR260	55	
48	2024-09-05	BR233	82	
73	2024-09-06	BR226	12	
74	2024-09-06	BR219	15	
75	2024-09-06	BR214	21	
...	
27396	2021-12-28	BR167	102	
27397	2021-12-28	BR161	112	
27398	2021-12-28	BR191	115	
27399	2021-12-29	BR155	134	
27403	2021-12-30	BR201	120	

	Separados	Entrega	Previsão De Instalação	...	\
47	55	05/09/2024	Desconhecido	...	
48	0	-	-	...	
73	0	-	-	...	
74	0	-	-	...	
75	0	-	-	...	
...	
27396	28/12/2021	28/12/2021	-	...	
27397	28/12/2021	28/12/2021	-	...	
27398	28/12/2021	28/12/2021	-	...	
27399	28/12/2021	28/12/2021	-	...	
27403	08/01/2022	30/12/2021	07/01/2022	...	

	Local de instalações	Status	Frete	Custo de cofre	\
47	PDI TRANSZERO CAÇAPAVA	Processing	91.15	17765.0	
48	PDI RENAULT	Processing	91.15	2004.0	
73	OPERAÇÃO RJ	Processing	91.15	17765.0	
74	OPERAÇÃO RJ	Processing	91.15	17765.0	
75	OPERAÇÃO RJ	Processing	91.15	17765.0	
...	
27396	ESTOQUE RIO DE JANEIRO	Done	91.15	121.0	
27397	ESTOQUE RIO DE JANEIRO	Done	91.15	121.0	
27398	ESTOQUE RIO DE JANEIRO	Done	91.15	121.0	
27399	ESTOQUE RIO DE JANEIRO	Done	91.15	121.0	
27403	PDI PIRACICABA	Done	91.15	121.0	

	Custo de instalação	IPI	CNPJ	para faturamento	Local de entrega	\
47	66.0	0.0	16.670.085/0001-55	Desconhecido		
48	66.0	0.0	07.976.147/0013-02	outro do cliente		
73	66.0	0.0	16.670.085/0001-55	mesmo do cliente		
74	66.0	0.0	16.670.085/0001-55	mesmo do cliente		
75	66.0	0.0	16.670.085/0001-55	mesmo do cliente		
...	
27396	66.0	0.0	Desconhecido	Desconhecido		

27397	66.0	0.0	Desconhecido	Desconhecido
27398	66.0	0.0	Desconhecido	Desconhecido
27399	66.0	0.0	Desconhecido	Desconhecido
27403	66.0	0.0	Desconhecido	Desconhecido

	Receita	Mês
47	3630.0	2024-09
48	5412.0	2024-09
73	792.0	2024-09
74	990.0	2024-09
75	1386.0	2024-09
...
27396	6732.0	2021-12
27397	7392.0	2021-12
27398	7590.0	2021-12
27399	8844.0	2021-12
27403	7920.0	2021-12

[4173 rows x 21 columns]

Análise Preditiva

```
In [26]: # Ordenando por 'Produto (nu cat)' e 'Mês'
df_sorted = df.sort_values(by=['Produto (nu cat)', 'Mês'])
```

```
In [27]: # Convertendo a coluna de datas para datetime e configurando como índice
df['Data de finalização (desejada)'] = pd.to_datetime(df['Data de finalização (desejada)'])
df.set_index('Data de finalização (desejada)', inplace=True)

# Selecionando apenas as colunas numéricas
df_numeric = df.select_dtypes(include=[np.number])

# Resample para garantir que o índice está definido com uma frequência consistente
df_resampled = df_numeric.resample('ME').mean() # Usando 'ME' para o último dia do mês

# Selecionando a coluna 'Receita' para análise
serie_temporal = df_resampled['Receita']

# Dividindo os dados em conjunto de treinamento e teste
train_size = int(len(serie_temporal) * 0.8)
train, test = serie_temporal[:train_size], serie_temporal[train_size:]

# Ajustando o modelo ARIMA com auto_arima
modelo_auto_arima = auto_arima(train, seasonal=False, stepwise=True, trace=True)
print(modelo_auto_arima.summary())

# Ajustando o modelo SARIMAX com os parâmetros encontrados
modelo_sarimax = SARIMAX(train, order=modelo_auto_arima.order)
resultado = modelo_sarimax.fit()
print(resultado.summary())

# Fazendo previsões
previsoes = resultado.get_forecast(steps=len(test))
previsoes_media = previsoes.predicted_mean
intervalo_confianca = previsoes.conf_int()

# Calculando erros
mae = mean_absolute_error(test, previsoes_media)
rmse = np.sqrt(mean_squared_error(test, previsoes_media))
```

```
print(f"Mean Absolute Error (MAE): {mae:.2f}")
print(f"Root Mean Squared Error (RMSE): {rmse:.2f}")

# Plotando os resultados
plt.figure(figsize=(12, 6))
plt.plot(serie_temporal.index, serie_temporal, label='Observado')
plt.plot(test.index, previsoes_media, color='red', label='Previsão')
plt.fill_between(test.index, intervalo_confianca.iloc[:, 0], intervalo_confianca.iloc[:, 1], color='pink', alpha=0.3)
plt.title('Previsão da Receita')
plt.xlabel('Data')
plt.ylabel('Receita')
plt.legend()
plt.show()

# Analisando os resíduos
residuos = resultado.resid
plt.figure(figsize=(12, 6))
plt.plot(residuos)
plt.title('Resíduos do Modelo')
plt.xlabel('Data')
plt.ylabel('Resíduos')
plt.show()

# Teste de normalidade dos resíduos
_, p_value = stats.normaltest(residuos)
print(f"P-valor do teste de normalidade dos resíduos: {p_value:.2f}")
```

```

Performing stepwise search to minimize aic
ARIMA(2,0,2)(0,0,0)[0]      : AIC=inf, Time=0.12 sec
ARIMA(0,0,0)(0,0,0)[0]      : AIC=468.415, Time=0.01 sec
ARIMA(1,0,0)(0,0,0)[0]      : AIC=428.627, Time=0.02 sec
ARIMA(0,0,1)(0,0,0)[0]      : AIC=451.989, Time=0.03 sec
ARIMA(2,0,0)(0,0,0)[0]      : AIC=428.603, Time=0.02 sec
ARIMA(3,0,0)(0,0,0)[0]      : AIC=430.480, Time=0.03 sec
ARIMA(2,0,1)(0,0,0)[0]      : AIC=inf, Time=0.07 sec
ARIMA(1,0,1)(0,0,0)[0]      : AIC=428.235, Time=0.05 sec
ARIMA(1,0,2)(0,0,0)[0]      : AIC=428.600, Time=0.08 sec
ARIMA(0,0,2)(0,0,0)[0]      : AIC=444.827, Time=0.05 sec
ARIMA(1,0,1)(0,0,0)[0] intercept : AIC=422.670, Time=0.03 sec
ARIMA(0,0,1)(0,0,0)[0] intercept : AIC=421.155, Time=0.04 sec
ARIMA(0,0,0)(0,0,0)[0] intercept : AIC=422.457, Time=0.01 sec
ARIMA(0,0,2)(0,0,0)[0] intercept : AIC=422.253, Time=0.06 sec
ARIMA(1,0,0)(0,0,0)[0] intercept : AIC=420.549, Time=0.02 sec
ARIMA(2,0,0)(0,0,0)[0] intercept : AIC=422.591, Time=0.03 sec
ARIMA(2,0,1)(0,0,0)[0] intercept : AIC=424.508, Time=0.09 sec

```

Best model: ARIMA(1,0,0)(0,0,0)[0] intercept
Total fit time: 0.756 seconds

SARIMAX Results

```

=====
Dep. Variable:          y      No. Observations:          27
Model:                 SARIMAX(1, 0, 0)      Log Likelihood      -207.275
Date:                 Wed, 11 Sep 2024      AIC                  420.549
Time:                 13:29:11      BIC                  424.437
Sample:              12-31-2021      HQIC                 421.705
                  - 02-29-2024
Covariance Type:          opg
=====

```

	coef	std err	z	P> z	[0.025	0.975]
intercept	748.4536	285.260	2.624	0.009	189.354	1307.553
ar.L1	0.3900	0.228	1.711	0.087	-0.057	0.837
sigma2	2.791e+05	7.33e+04	3.810	0.000	1.36e+05	4.23e+05

```

=====
Ljung-Box (L1) (Q):          0.00      Jarque-Bera (JB):          11.34
Prob(Q):                    0.96      Prob(JB):                  0.00
Heteroskedasticity (H):      1.11      Skew:                      1.22
Prob(H) (two-sided):        0.88      Kurtosis:                  5.03
=====

```

Warnings:

```

[1] Covariance matrix calculated using the outer product of gradients (complex-step).
RUNNING THE L-BFGS-B CODE

```

* * *

Machine precision = 2.220D-16

N = 2 M = 10

At X0 0 variables are exactly at the bounds

At iterate 0 f= 7.86366D+00 |proj g|= 5.46266D-03

* * *

Tit = total number of iterations

Tnf = total number of function evaluations

Tnint = total number of segments explored during Cauchy searches
Skip = number of BFGS updates skipped
Nact = number of active bounds at final generalized Cauchy point
Projg = norm of the final projected gradient
F = final function value

* * *

N	Tit	Tnf	Tnint	Skip	Nact	Projg	F
2	4	6	1	0	0	1.674D-05	7.863D+00

F = 7.8634545866096710

CONVERGENCE: REL_REDUCTION_OF_F_<=_FACTR*EPSMCH
SARIMAX Results

Dep. Variable:	Receita	No. Observations:	27
Model:	SARIMAX(1, 0, 0)	Log Likelihood	-212.313
Date:	Wed, 11 Sep 2024	AIC	428.627
Time:	13:29:11	BIC	431.218
Sample:	12-31-2021	HQIC	429.397
	- 02-29-2024		
Covariance Type:	opg		

	coef	std err	z	P> z	[0.025	0.975]
ar.L1	0.8862	0.104	8.505	0.000	0.682	1.090
sigma2	3.702e+05	6.72e+04	5.510	0.000	2.39e+05	5.02e+05

Ljung-Box (L1) (Q):	2.86	Jarque-Bera (JB):	12.58
Prob(Q):	0.09	Prob(JB):	0.00
Heteroskedasticity (H):	1.79	Skew:	1.21
Prob(H) (two-sided):	0.40	Kurtosis:	5.31


Warnings:


[1] Covariance matrix calculated using the outer product of gradients (complex-step).

Mean Absolute Error (MAE): 880.90

Root Mean Squared Error (RMSE): 941.98

This problem is unconstrained.






P-valor do teste de normalidade dos resíduos: 0.01

Previsão da Receita para 2024

```
In [28]: # Ajustando o modelo ARIMA
modelo = ARIMA(serie_temporal, order=(1, 0, 0)) # Ordem pode ser ajustada conforme o resultado da análise de AIC
resultado = modelo.fit()

# Previsão para o futuro
previsao = resultado.get_forecast(steps=12) # Previsão para 12 meses
previsao_media = previsao.predicted_mean
previsao_intervalo = previsao.conf_int()

# Visualizando a previsão
plt.figure(figsize=(12, 6))
plt.plot(serie_temporal, label='Observado')
plt.plot(previsao_media, color='red', label='Previsão')
plt.fill_between(previsao_intervalo.index, previsao_intervalo.iloc[:, 0], previsao_intervalo.iloc[:, 1], color='red', alpha=0.3)
plt.title('Previsão da Receita para 2024')
plt.xlabel('Data')
plt.ylabel('Receita')
plt.legend()
plt.show()
```




Análise de Cenários

```
In [29]: # Ajustando parâmetros
def ajustar_crescimento(serie, taxa_crescimento):
    serie_ajustada = serie.copy()
    for i in range(1, len(serie_ajustada)):
        serie_ajustada.iloc[i] = serie_ajustada.iloc[i - 1] * (1 + taxa_crescimento)
    return serie_ajustada

# Analisando diferentes cenários
taxas_crescimento = [0.01, 0.05, 0.10]
for taxa in taxas_crescimento:
    serie_cenario = ajustar_crescimento(serie_temporal, taxa)
    plt.plot(serie_cenario, label=f'Taxa de Crescimento: {taxa*100}%')

plt.plot(serie_temporal, label='Original', color='black')
plt.title('Cenários de Crescimento da Receita')
plt.xlabel('Data')
plt.ylabel('Receita')
plt.legend()
plt.show()
```



Visualização e Relatórios

```
In [30]: # Obtendo os resíduos
residuos = resultado.resid

# Teste de Jarque-Bera para normalidade dos resíduos
jb_test = sm.stats.jarque_bera(residuos)

# Extraíndo valores do teste
jb_stat = jb_test[0] # Estatístico do teste
jb_pvalue = jb_test[1] # P-valor

# Criando o relatório atualizado
print('Relatório de Previsão e Análise Preditiva')
print('=====')
print(f'\nModelo ARIMA selecionado: ARIMA(1,0,0)')
print(f'\nMédia da Receita Prevista para 2024:')
print(previsao_media.describe())
print(f'\nErro Médio Absoluto (MAE): {resultado.mse}')
print(f'\nErro Quadrático Médio (RMSE): {np.sqrt(resultado.mse)}')
print(f'\nP-valor do teste de Jarque-Bera dos resíduos: {jb_pvalue}')
```

Relatório de Previsão e Análise Preditiva

=====

Modelo ARIMA selecionado: ARIMA(1,0,0)

Média da Receita Prevista para 2024:

```
count      12.000000
mean      1246.039084
std        11.333947
min       1211.439683
25%       1249.170396
50%       1250.508903
75%       1250.548876
max       1250.549973
Name: predicted_mean, dtype: float64
```


Erro Médio Absoluto (MAE): 254378.53595053294

Erro Quadrático Médio (RMSE): 504.3595304448335

P-valor do teste de Jarque-Bera dos resíduos: 0.040963514847225775

```
count 12.000000 mean 1246.039084 std 11.333947 min 1211.439683 25% 1249.170396 50% 1250.508903 75% 1250.548876 max 1250.549973 Name: predicted_mean, dtype: float64
```

```
In [31]: # Gráfico da série temporal e previsões
plt.figure(figsize=(12, 6))
sns.lineplot(data=serie_temporal, label='Receita Original')
sns.lineplot(data=previsao_media, label='Previsão ARIMA', color='red')
plt.fill_between(previsao_intervalo.index, previsao_intervalo.iloc[:, 0], previsao_intervalo.iloc[:, 1], color='red', alpha=0.3)
plt.title('Receita Original e Previsões')
plt.xlabel('Data')
plt.ylabel('Receita')
plt.legend()
plt.show()
```



Gráficos Interativos

(só funciona no Jupyter Notebook)

```
In [32]: # Convertendo a coluna 'Data de finalização (desejada)' para datetime
df.index = pd.to_datetime(df.index, format='%Y-%m-%d')


# Criando uma série temporal para 'Receita'
serie_temporal = df[['Receita']].copy()

# Criando o gráfico interativo
fig = go.Figure()

# Adicionando a série temporal da receita ao gráfico
fig.add_trace(go.Scatter(x=serie_temporal.index, y=serie_temporal['Receita'],
                        mode='lines+markers',
                        name='Receita',
                        line=dict(color='royalblue', width=2),
                        marker=dict(size=6, color='royalblue', symbol='circle'))))

# Atualizando o layout do gráfico
fig.update_layout(
    title='Desempenho Financeiro ao Longo do Tempo',
    xaxis_title='Data',
    yaxis_title='Receita',
    template='plotly_white')
```

```
)  
  
# Exibindo o gráfico  
fig.show()
```



```
In [33]: # Criando um gráfico de barras empilhadas por segmento  
fig = px.bar(df, x=df.index, y='Receita', color='Segmento', title='Receita por Segmento ao Longo do Tempo',  
            labels={'Receita': 'Receita', 'Data de finalização (desejada)': 'Data'})  
fig.update_layout(barmode='stack')  
fig.show()
```


/Users/tsumano/opt/anaconda3/lib/python3.9/site-packages/plotly/express/_core.py:1979: FutureWarning:

When grouping with a length-1 list-like, you will need to pass a length-1 tuple to get_group in a future version of pandas. Pass `(name,)` instead of `name` to silence this warning.

/Users/tsumano/opt/anaconda3/lib/python3.9/site-packages/_plotly_utils/basevalidators.py:106: FutureWarning:


The behavior of DatetimeProperties.to_pydatetime is deprecated, in a future version this will return a Series containing python datetime objects instead of an ndarray. To retain the old behavior, call `np.array` on the result

Receita por Segmento ao Longo do Tempo




```
In [34]: fig = px.box(df, y='Receita', title='Distribuição da Receita')
fig.show()
```


Distribuição da Receita



```
In [35]: fig = px.scatter(df, x='Custo de instalação', y='Receita', title='Relação entre Custo de Instalação e Receita',  
                        labels={'Custo de instalação': 'Custo de Instalação', 'Receita': 'Receita'})  
fig.show()
```

Relação entre Custo de Instalação e Receita



```
In [36]: fig = go.Figure()


# Linha da receita
fig.add_trace(go.Scatter(x=serie_temporal.index, y=serie_temporal['Receita'],
                        mode='lines+markers', name='Receita',
                        line=dict(color='royalblue', width=2),
                        marker=dict(size=6, color='royalblue', symbol='circle'))))

# Linha de tendência
fig.add_trace(go.Scatter(x=serie_temporal.index, y=serie_temporal['Receita'].rolling(window=12).mean(),
                        mode='lines', name='Tendência',
                        line=dict(color='red', width=2, dash='dash'))))

fig.update_layout(
    title='Desempenho Financeiro com Tendência',
    xaxis_title='Data',
    yaxis_title='Receita',
    template='plotly_white'
)

fig.show()
```

Desempenho Financeiro com Tendência



```
In [37]: # Preparando os dados para o gráfico de radar
dados_segmento = df.groupby('Segmento').agg({'Receita': 'sum'}).reset_index()

# Criando o gráfico de radar
fig = go.Figure()

# Adicionando cada segmento ao gráfico
for segmento in dados_segmento['Segmento']:
    dados = dados_segmento[dados_segmento['Segmento'] == segmento]
    fig.add_trace(go.Scatterpolar(
        r=dados['Receita'],
        theta=[segmento] * len(dados),
        fill='toself',
        name=segmento
    ))

# Atualizando o layout do gráfico
fig.update_layout(
    polar=dict(
        radialaxis=dict(visible=True, range=[0, dados_segmento['Receita'].max()]),
    ),
    showlegend=True,
    title='Comparação de Receita por Segmento'
)

fig.show()
```

Comparação de Receita por Segmento

